

GR00T N1:

An Open Foundation Model for Generalist Humanoid Robots

VIA 스터디 – 세미나 4

학부연구생 나유빈
2026-08-05 (수)

1. Introduction

Groot-N1

An Open Foundation Model for Generalist Humanoid Robots

발행/공개: 2025년 (2025년 3월 arXiv 공개), 소속 기관: NVIDIA

내용: 오픈 파운데이션 모델이자 이중-시스템 아키텍처를 사용하는 VLA,
주로 Cross-embodiment와 효과적인 데이터 활용을 다룸



Isaac GROOT

학습 데이터, 시뮬레이션 벤치마크: [GitHub](#), [HuggingFace_Datasets](#)
소개 페이지: [Isaac](#)

1. Introduction

Groot-N1

로봇이 human-level physical intelligence를 가지기 위해 3가지 조건을 달성해야 함.

1. 휴머노이드

인간의 다재다능함을 모방하기 위함

2. Generalist model

환경과 task가 계속 변하기 때문

3. 효과적인 데이터 전략

로봇 데이터 수집 (특히 휴머노이드)는 데이터 수집이 비싸고 오래걸리기 때문

1. Introduction

Groot-N1

3. 효과적인 데이터 전략

로봇 데이터 수집 (특히 휴머노이드)는 데이터 수집이 비싸고 오래걸리기 때문

< - Groot는 이 특징에 집중함

비전 및 텍스트 모델의 foundation 모델은 강한 일반화를 위해 웹규모 데이터가 필요함
그러나 휴머노이드는 웹규모의 데이터가 부재

OpenVLA, $\pi 0$ 가 사용하는 로봇학습커뮤니티 Open X-Embodiment(OXE,)가 있긴 하지만,
임베디먼트, 센서, 자유도, 제어모드가 제각각이라 여전히 “데이터섬” 문제가 발생

- +) 휴머노이드 데이터가 거의 없고 탁상형 단일팔 + 평행그리퍼에 쏠려있음.
- +) 양 자체도 부족함

1. Introduction

Groot-N1

이 OXE의 데이터 섬 문제를 해결하기 위해 피라미드 형 데이터 구조를 활용하고 Co-training 전략을 활용



위로 올라갈수록 data 양은 줄고 임베디먼트 특이성은 커진다.

-> Co-training 전략으로 사전/post 학습 모두 세가지 데이터를 활용함.

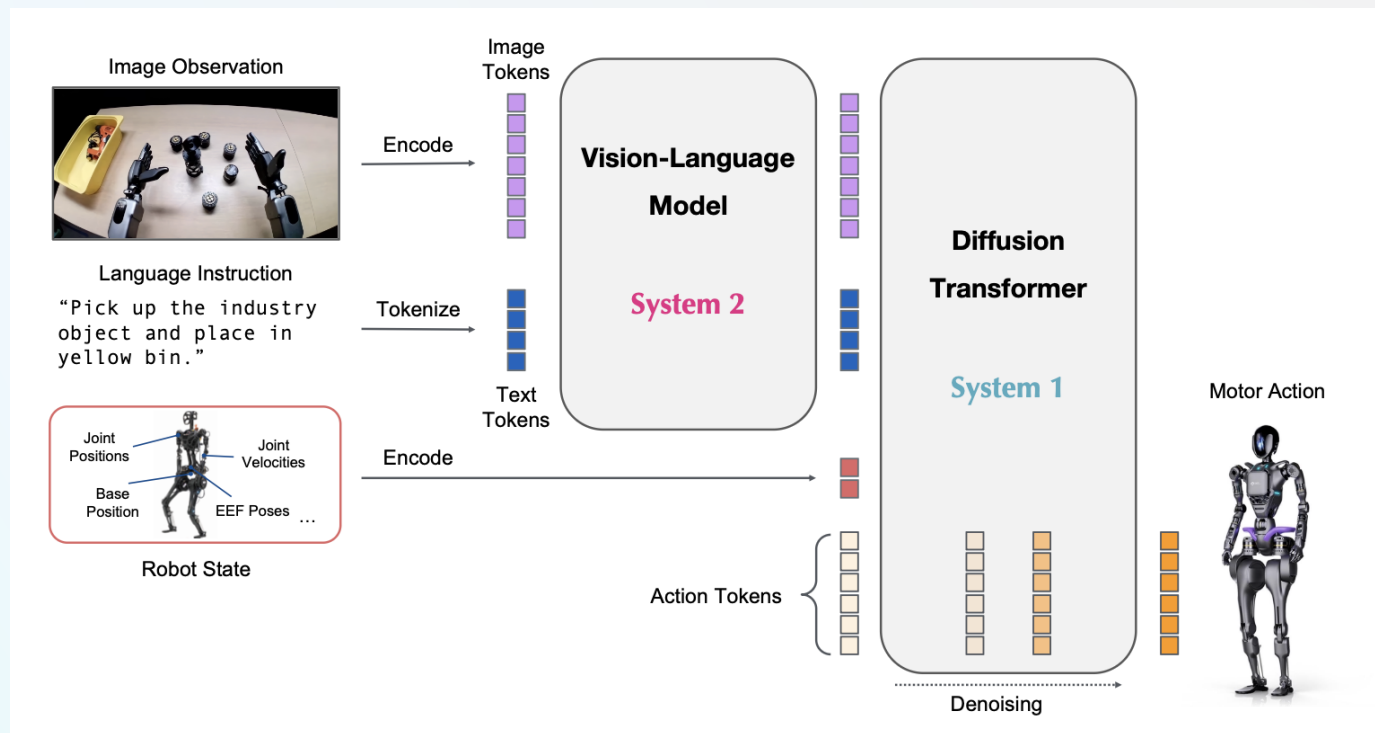
2. Model Architecture

입력 : robot state, image, 지시, 노이즈화 된 액션 토큰
출력 : 대응하는 모터 액션


시스템 2: VLM, (10Hz, L40에서)

시스템 1: action flow-matching,
closed-loop

-> 두 시스템이 강하게 결합함(교차주의/ 함께 최적화)




2. Model Architecture



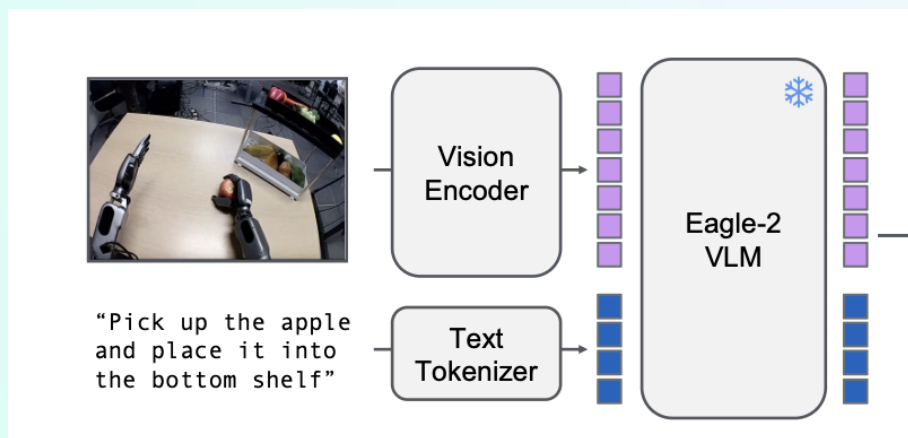
항목	값
전체 파라미터	2.2B
VLM	1.34B
나머지(DiT + 어댑터)	약 0.86B
16개 액션 청크 샘플링	63.9ms (L40, bf16)

$\pi 0$ 의 액션 전문가(300M)에 비해 DiT크기가 매우 크다.

2. Model Architecture



2. Model Architecture



Eagle-2 VLM


SmolLM2 LLM + SigLIP-2(이미지 인코더)를 정렬해 파인튜닝한 모델

SmolLM2 LLM은 OpenVLA나 파이제로와 다르게 매우 작은 LLM이다.

Eagle-2, SmolLM2, SigLIP-2 모두 이미 만들어져 있는 모델이다.

Eagle-2의 출력은 더 빠르고 유용한 중간레이어(12번째)를 활용함.

입력: 복수/ 하나의 이미지를 224x224로 강제 re-sizing해서 입력
학습 시에는 사용한 채팅 포맷 그대로 태스크 설명 + (복수의) 이미지를 입력




출력: (배치 × 시퀀스 길이 × 히든) 형태의 비전-언어 특징 ϕ_t
이미지는 $224 \times 224 \rightarrow$ pixel shuffle $\rightarrow$ 프레임당 64개 토큰

사전 학습, 포스트 학습 모두 텍스트 토크나이저는 frozen, 비전 인코더를 포함하는 나머지 전체 모델은 unfrozen 상태로 학습

2.1. GROOT N1 Foundation Model

Vision-Language Module - 특징




- Flow-matching을 사용하여 action 생성을 학습한다.

- 적응형 레이어 정규화를 사용한다. 적응형 레이어 정규화는 조건부 입력값을 활용해 정규화된 값에 곱해질 스케일(γ)과 더해질 바이어스(β)를 실시간으로 계산하기 때문에 타임스텝 입력도 필요하다.

- 두가지 인코더와 하나의 디코더는 플랫폼에 따라서 재학습된다.

2.1. GROOT N1 Foundation Model

Vision-Language Module




입력 : 상태(로봇마다 차원이 다름), ACT처럼 액션 청크를 사용(16개로 끊어서, 로봇마다 차원이 다름)

단, Encoder에 넣기 전에 형식을 표준화 시킴.(부록 E.2)

- State encode: 임베디먼트마다 다른 차원을 Dit가 알아듣게 통일 시킨다.
- Action Encoder: 타임스텝을 함께 인코딩해서 Dit가 알아듣게 차원을 통일 시킨다.

2.1. GROOT N1 Foundation Model

Vision-Language Module



DiT블록에는


변환된 state와 한 차원에 한 스텝이 포함되어 있는 노이즈 처리된 action 청크 16차원이 입력된다

Cross attention에서는 비전-언어 토큰 임베딩을 조건으로 사용할 수 있게 하고

Self attention은 노이즈가 포함된 액션 토큰 임베딩과 state 임베딩을 처리한다.

2.1. GROOT N1 Foundation Model

Vision-Language Module




Action Decoder에서는 각 로봇의 임베디먼트에 맞는 차원으로 변환한다. State는 사용하지 않고 action만 사용한다.

이 차원은 벡터값으로, 다시 노이즈 액션으로 입력되어 flow matching의 속도장으로 쓰인다.

이 과정을 ($K=4$)4번 반복해서 노이즈 없는 액션 예측 A_t 를 만들어낸다.

2.1. GROOT N1 Foundation Model

Vision-Language Module



4스텝 적분이 하는 일

$A^0 = \text{랜덤 노이즈}$

$A^1 = A^0 + (1/4) \cdot V(A^0)$ ← 지금 위치에서 방향 물어보고 1/4만큼 이동

$A^2 = A^1 + (1/4) \cdot V(A^1)$

$A^3 = A^2 + (1/4) \cdot V(A^2)$

$A^4 = A^3 + (1/4) \cdot V(A^3)$ ← 최종 액션

출력:

A^4 가 완성되면 모터 액션으로 전달한다.
전달하는 형태는 매번 다르게 나타났는데,
지정할 수 있는 것으로 보인다.

단, 4번이 반복되는 동안, 파라미터가 많은
Eagle-2는 딱 한번만 실행된다.

2.2 Training Data Generation



2.2 Training Data Generation


3가지 개념

1. Latent Actions

사람 중심 영상과 신경학습으로 생성된 영상들은 액션이 없어서 학습에 쓰일 수 없다

VQ-VAE 모델을 활용 - 목적함수 활용

현재 프레임
 X_t 과
H시간 뒤의 프레임
 X_{t+H} 를
입력



X_{t+H} 를 재구성

인코더가
액션 Z_t 를 출력

디코더가 Z_t 와 X_t 를
입력받음

2.2 Training Data Generation

3가지 개념


1. Latent Actions

사람 중심 영상과 신경학습으로 생성된 영상들은 액션이 없어서 학습에 쓰일 수 없다

VQ-VAE 모델을 활용

이 인코더를
역동역학 모델로서(IDM) 활용!

현재 프레임
 X_t 과
H시간 뒤의 프레임
 X_{t+H} 를
입력



X_{t+H} 를 재구성

인코더가
액션 Z_t 를 출력

디코더가 Z_t 와 X_t 를
입력받음

2.2 Training Data Generation

3가지 개념

1. Latent Actions

VQ-VAE모델로 학습시킨 인코더에 시작과 끝 프레임들을 입력해 위 영상들의 액션을 뽑아 온다.

**학습할 땐 VQ-VAE모델의 코드북으로 양자화한 뒤에 flow-matching에 다른 로봇 데이터와 동일하게 사용한다.
대신 구분을 위해 LAPA라는 라벨을 붙인다.**

주의!

IDM은 로봇 데이터만으로 DiT+SigLIP-2를 학습시켜 액션을 출력하는 모델이다. 여기에선 LAPA가 IDM 역할만 하는 것일 뿐, IDM은 아니다.

2.2 Training Data Generation

3가지 개념

1. Latent Actions



Figure 4: **Latent Actions.** We retrieve similar latent embeddings across various embodiments. The left images illustrate the latent action that corresponds to moving the right arm (or hand) to the left, while the right images illustrate the latent action that corresponds to moving the right arm (or hand) to the right. Note that this general latent action is not only consistent in different robot embodiments, but also in human embodiment.

2.2 Training Data Generation

3가지 개념

2. Neural trajectories

영상 생성 모델들을 발전을 이용해, 실제 GR-1 휴머노이드로 측정한 데이터를 파인튜닝해, 데이터를 증강했다.

WAN2.1-12V-14B를 LORA로 파인튜닝해서 827시간의 데이터로 증강

1. LLM에게 초기 프레임의 객체를 탐지하게 함
2. “pick up {object} from {location A} to {location B}” 같이 가능한 조합들을 모두 생성한 뒤 WAN2.1-1 2V-14B를 통해서 영상을 생성시킨다
3. 만들어진 영상을 LLM을 사용해서 필터링하고, 실패한 영상은 8개의 프레임으로 다운 샘플링해서 주석을 다시 달아 새로 생성한다.

2.2 Training Data Generation

3가지 개념

2. Neural trajectories

3000개의 실로봇 샘플을 주석 포함해서 100에포크로 학습시킴

각 샘플은 480P resolution, 81개의 프레임, 총 827시간 정도 길이의 영상들을 생성함

L40 1장에 1초영상을 만드는데 2분, L40 3600장으로 105k L40 GPU hour걸림(1.5일)

Latent action, IDM 둘 다 라벨링해서 사전 학습

Prompt: use the right hand to pick up cucumber to basket



Prompt: use the left hand to pick up spray bottle to basket



Prompt: use the left hand to pick up spray bottle to beige bowl



Prompt: pick up can from cutting board to pan



Prompt: pick up apple from cutting board to pan



Prompt: pick up tools from mesh cup to clear bin



Prompt: pick up the potato, place it into the microwave and close the microwave



2.2 Training Data Generation

3가지 개념

3. Simulation Trajectories

DexMimicGen을 활용해 소수의 로봇 데이터를 증강한다.

고자유도 다지(Multi-fingered) 로봇 손의 대규모 모동(Demonstration) 데이터를 자동으로 생성해 주는 프레임워크임

1) 소수 시연 수집 및 하위 작업 분할

사람이 텔레옴으로 수행한 몇 안 되는 시연 데이터를 수집하고, 이를 의미 있는 하위 단계(예: 접근 -> 파지 -> 회전/이동 -> 놓기)로 나눈다. Task도 동일하게 하위단계로 나누고 이를 직접 시연한 데이터와 대응시킨다.

2) 객체 중심 좌표계 변환 (Object-Centric Transformation)

새로운 환경을 만들어서 task를 만들면, 대응되는 사람의 데이터를 객체에 맞춰 정렬한다.

2.2 Training Data Generation

3가지 개념

3. Simulation Trajectories

3) 다지 관절 궤적 보정 (Dexterous Trajectory Adaptation)

물체 변화에 따라 손가락 관절 각도를 재조정합니다. 대응할 때 엔드이펙터와 객체사이의 상대포즈를 보존시킬 수 있게 수정한다. 수정한 뒤 부족한 액션을 보간한다.

4) 시뮬레이션 실행 및 필터링 (Sim-based Rollout & Filtering)

변형된 궤적을 물리 시뮬레이터(Isaac Sim / MuJoCo 등)에서 실제로 구동해 보고, 성공한 궤적만 자동 추출하여 대규모 데이터셋으로 저장한다.

이를 통해 780,000개의 시뮬레이션 궤적을 생성함.

Isaac Lab 2.2 버전 이후에도 다중 말단 장치(Multi-eef) 기반의 DexMimicGen 데이터 생성을 공식적으로 지원하기 시작하여, 시뮬레이션 환경에서 양팔/다지 손 데이터를 더욱 쉽게 증강할 수 있도록 통합되었음.

2.2 Training Data Generation

사전 학습에 사용된 데이터 < – flow-matching의 손실함수에 사용

1. 사람 데이터를 활용한 latent action (LAPA)
2. 로봇 실제 액션 실제 액션
3. 로봇 실제 액션의 영상으로 만든 latent action
4. Neural trajectory로 생성한 영상을 보고 IDM으로 action을 생성한 데이터셋
5. Neural trajectory로 생성한 영상을 보고 latent action을 생성한 데이터셋 (LAPA)
6. 시뮬레이션 궤적

	Latent Actions	Neural Trajectories	Simulation Trajectories
Real-Robot Datasets	✓	✓	✓
Simulated Robot Datasets	✓	✓	
Human Video Datasets	✓		


2.2 Training Data Generation - 사전 학습에 사용된 데이터 -

실제 로봇으로 측정한데이터(사전학습 용)

1. GROOT N1 Humanoid pre-Training DataSet
2. Open X-Embodiment
3. AgiBot-Alpha

2.2 Training Data Generation - 사전 학습에 사용된 데이터 -

실제 로봇으로 측정한 데이터



1. GROOT N1 Humanoid pre-Training DataSet

측정 방법 : ViveUltimate Tracker (손목) + XsensMetagloves-설명/Manus Glove-figure 6 (손가락)
또는 Apple Vision Pro 또는 Leap Motion(적외선 손 추적 프로그램)

방법: 측정한 사람 동작을 역기구학으로 휴머노이드 액션으로 리타겟팅 (제어주파수 20Hz) -> 관절값 + 휴머노이드
카메라 정보 추출

학습시킬 때만 사용하는 주석을 fiine-grained/coarse-grained로 나눠서 추가함.

2.2 Training Data Generation - 사전 학습에 사용된 데이터 -

실제 로봇으로 측정한 데이터

2. Open X-Embodiment

다양한 조작 task와 언어 조건부 제어, 로봇-환경 상호작용을 제공하는 데이터셋 선별

데이터셋 명칭	로봇 플랫폼 (Embodiment)	주요 연구 기관
Fractal 2020 / RT-1	Everyday Robots (Google)	Google DeepMind
BridgeData V2	WidowX 250	UC Berkeley
Language-Table	xArm 6	Google DeepMind
ALOHA / Mobile ALOHA	Bimanual ViperX 300	Stanford University
DROID	Franka Emika Panda	DROID Consortium
TACO Play	Franka Emika Panda	LMU Munich
RoboSet	Franka Emika Panda	CMU
BC-Z	Google Robot	Google
NYU / Columbia / UT Austin	UR5, Kinova Jaco, Sawyer 등	각 대학 연구실

2.2 Training Data Generation - 사전 학습에 사용된 데이터 -

실제 로봇으로 측정한 데이터

3. AgiBot-Alpha

실제 로봇 데이터의 60%를 차지함.

로봇 100대에서 수집한 대규모 set, 세밀한 조작, 도구사용, 다중로봇협업에 대한 데이터 셋을 포함함.

140,000 트라젝토리 사용됨

2.2 Training Data Generation - 사전 학습에 사용된 데이터 -

시뮬레이션 트래젝토리

1. 휴머노이드가 다양한 탁상 재배치 태스크를 수행 - 사실적인 3D 에셋 다수 배치
2. 위 사항을 RoboCasa 시뮬레이션 프레임워크 위에 구축 (Nasiriany et al., 2024)
3. 물체와 리셉터클을 테이블 위 무작위 위치에 배치
4. 방해 물체(distractor)와 방해 리셉터클을 추가로 넣음

태스크 구조: "A를 B에서 C로 재배치" — A는 물체, B와 C는 출발/도착 위치

출발·도착 위치는 접시, 바구니, 플레이스매트, 선반 같은 리셉터클

사전학습 시뮬 데이터셋은 54개의 고유한 (출발, 도착) 리셉터클 조합

2.2 Training Data Generation

시뮬레이션 트래젝토리

5. Leap Motion으로 텔레오퍼해 수십 개(a few dozen)의 소스 시연 수집(GR-1 휴머노이드 대상이지만 다른 로봇에도 적용 가능)
6. Leap Motion이 6-DoF 손목 포즈와 손가락 포즈를 추적 → mink 기반 whole-body IK 컨트롤러로 전송
7. DexMimicGen이 시연을 객체 중심 구간으로 처리한 뒤 변환·조합해 새 시연 생성

(출발, 도착) 리셉터클 쌍마다 10,000개 생성 → 총 540k




Figure 6: **Data Collection via Teleoperation.** Our teleoperation infrastructure supports multiple devices to capture human hand motion, including 6-DoF wrist poses and hand skeletons. Robot actions are produced through retargeting and executed on robots in real and simulation environments.

2.2 Training Data Generation

사전 학습에 사용된 데이터 - 인간 영상 데이터 셋

Ego4D	154.4M	2,144.7	20	Egocentric	Human
Ego-Exo4D	8.9M	123.0	30	Egocentric	Human
Assembly-101	1.4M	19.3	20	Egocentric	Human
HOI4D	892K	12.4	20	Egocentric	Human
HoloAssist	12.2M	169.6	20	Egocentric	Human
RH20T-Human	1.2M	16.3	20	Egocentric	Human
EPIC-KITCHENS	2.3M	31.7	20	Egocentric	Human
GR-1 Simulation Pre-Training	125.5M	1,742.6	20	Egocentric	Simulation
GR-1 Neural Videos	23.8M	827.3	8	Egocentric	Neural-generated

각 데이터셋 내용 - 논문 내용 발췌 및 번역 (11페이지)

- Ego4D**: 일상적인 활동들의 다양한 녹화본을 포함하는 대규모 1인칭(egocentric) 비디오 데이터셋입니다. (Grauman et al., 2022)
- Ego-Exo4D**: 1인칭 시점의 영상과 더불어 이를 보완해 주는 3인칭(exocentric) 시점의 영상을 추가로 제공합니다. (Grauman et al., 2024)
- Assembly-101**: 객체를 단계별로 조립하는 상세한 비디오를 제공하여 복잡한 조립 작업에 중점을 둡니다. (Sener et al., 2022)
- EPIC-KITCHENS**: 요리 활동에 대한 1인칭 시점의 영상들을 포함하고 있습니다. (Damen et al., 2018)
- HOI4D**: 프레임 단위의 분할(segmentation), 손과 객체의 자세(poses), 그리고 행동(actions)에 대한 주석(annotations)과 함께 인간-객체 상호작용(human-object interactions)을 포착합니다. (Liu et al., 2022)
- HoloAssist**: 증강 현실(augmented reality) 환경 내에서 이루어지는 협력적이고 보조적인 작업들을 기록합니다. (Wang et al., 2023)
- RH20T-Human**: 다양한 실제 시나리오 전반에 걸쳐 자연스러운 손-객체 상호작용에 중점을 두며, 세밀한 조작(fine-grained manipulation) 작업의 녹화본을 포함합니다. (Fang et al., 2023)

2.2 Training Data Generation

post 학습 방법

GR00T N1은 Pre-training(전체 data pyramid로 범용 능력 학습) 이후, 실제 배포할 각 임베디먼트(로봇 종류)마다 별도로 Post-training(파인튜닝)을 진행

Pre-training과 동일하게, VL 백본의 언어(텍스트) 부분만 계속 고정(frozen)
그 외 나머지(vision encoder, State/Action Encoder-Decoder, DiT 전체)는 전부 학습 가능하게 열어둠

Table 6: Training hyperparameters. Pre- and post-training use the same hyperparameters unless specified.

Hyperparameter	Pre-training Value	Post-training Value
Learning rate	1e-4	
Optimizer	AdamW	
Adam beta1	0.95	
Adam beta2	0.999	
Adam epsilon	1e-8	
Weight decay	1e-5	
LR scheduler	cosine	
Warmup ratio	0.05	
Batch size	16,384	128 or 1024
Gradient steps	200,000	20,000 – 60,000
Backbone’s vision encoder	unfrozen	
Backbone’s text tokenizer	frozen	
DiT	unfrozen	

-> 작은 배치 사이즈 + 적은 최적화 스텝 수

DexMimicGen Cross-Embodiment Suite처럼 태스크 수가 적고 데이터가 제한적인 경우엔 batch size를 128로 축소

2.2 Training Data Generation

post 학습에 쓰인 데이터

(1) 실로봇 데이터 (임베디먼트별 human demonstration)

사람 operator가 벤치마크 태스크당 15분~3시간 정도 직접 텔레오퍼레이션으로 수집 -> 이후 품질 낮은 궤적은 필터링해서 제거

실험에서는 데이터 규모별 성능 확인:

- 시뮬레이션 벤치마크: 태스크당 30 / 100 / 300개 demonstration
- 실제 로봇(GR-1 humanoid): 전체 데이터의 10% vs Full data 두 세팅으로 비교 (데이터 효율성 검증 목적)

실제 로봇 벤치마크는 4개 카테고리 구성:

- Pick-and-Place (5개 태스크)
- Articulated Object Manipulation (3개 태스크)
- Industrial Object Manipulation (3개 태스크)
- Multi-Agent Coordination (2개 태스크)

2.2 Training Data Generation

post 학습에 쓰인 데이터

(2) Neural Trajectory (합성 영상 데이터) — Post-training 전용 증강 기법

Pre-training에서 쓴 방식과 비슷하지만, 벤치마크 태스크에 맞춰 다시 생성함.

-> 입력 비디오가 복수인 경우 비디오 생성 모델을 grid 형태의 multi-subimage를 생성하도록 파인튜닝

- 시뮬레이션 태스크: 랜덤 초기화된 환경에서 다양한 초기 프레임을 수집해 시작점으로 사용
- 실로봇 태스크: 사람이 물체 위치를 수동으로 랜덤 배치하고 초기 관찰 이미지를 기록해 시작점으로 사용

현실적인 저데이터 시나리오를 흉내내기 위해, 비디오 생성 모델 자체도:

- 시뮬레이션 태스크는 사람이 수집한 데모만으로 파인튜닝(DEXMimic 사용 X)
- 실로봇 태스크는 post-training용 벤치마크 데이터의 10%만 사용해 파인튜닝

생성된 영상에는 action label이 없으므로, Latent action 또는 IDM(Inverse Dynamics Model) 으로 라벨링한 pseudo-action을 사용 (저데이터 상황을 재현하기 위해 IDM도 저데이터로만 학습)

2.2 Training Data Generation

전체 학습에 쓰인 infrastructure

구분 (Category)	내용 (Details)
오케스트레이션 플랫폼	복잡한 로보틱스 워크로드 확장을 위한 NVIDIA OSMO 관리 클러스터 사용 (NVIDIA, 2025)
하드웨어 및 네트워크 구성	팻트리(fat-tree) 토폴로지의 NVIDIA Quantum-2 InfiniBand로 연결된 NVIDIA H100 GPU 탑재
분산 컴퓨팅 및 데이터 수집	Ray 분산 컴퓨팅 라이브러리 기반의 커스텀 라이브러리를 통해 결함 허용(fault-tolerant) 다중 노드 학습 및 데이터 수집 지원 (Moritz et al., 2018)
학습 규모 및 비용	- 단일 모델당 최대 1024개의 GPU 사용 - GR00T-N1-2B 사전 학습에 약 50,000 H100 GPU 시간 소요
컴퓨팅 제약 미세 조정 (Finetuning)	- 단일 A6000 GPU 환경에서 테스트됨 - 어댑터 레이어(액션 및 상태 인코더 + 액션 디코더) 및 DiT 튜닝 시: 최대 200의 배치 크기(batch size) 사용 가능 - 비전 인코더 튜닝 시: 최대 16의 배치 크기(batch size) 사용 가능

평가

평가 벤치마크

시뮬레이션

벤치마크	태스크 수	로봇	특징
RoboCasa Kitchen	24개	Franka Panda 팔	pick-and-place, 문 열기/닫기, 버튼 누르기 등 기초 동작 Post-train 30/100/300학습
DexMimicGen Suite	9개	Bimanual Panda / GR-1 휴머노이드	양손 협응이 필요한 정교한 조작
GR-1 Tabletop	24개	GR-1 휴머노이드 (dexterous hands)	다양한 물체·용기 조합의 rearrangement

실제 실험

실제로봇 벤치마크 4종 (GR-1 휴머노이드): Pick-and-Place(5), Articulated(3), Industrial(3), Coordination(2)



Pre-training 자체의 평가- GR-1

파인튜닝 안 한 사전학습 체크포인트만으로 얼마나 일반화되는지 테스트한 부분

Task 1 (양손 협응): 물체를 왼손 근처에 일부러 배치 → 왼손으로 집어서 오른손에 넘긴 뒤 배치해야 하는 상황
(본 적 없는 상황)
76.6% (11.5/15) 성공

Task 2 (미지 물체 → 미지 용기): 학습에서 못 본 새로운 물체를 못 본 새로운 용기에 배치
73.3% (11/15) 성공


Pre-Training Evaluations

Prompt:
pick up
green bell
pepper to
bottom shelf



Pick-and-Place with Left-to-Right Handover

Prompt:
pick up
peach to
yellow bin




Pick up Novel Object to Novel Container



Post-training 결과 — 시뮬레이션

100 demonstration 기준 평균 성공률(%)



세 벤치마크 모두에서 from-scratch 베이스라인을 상회

격차가 가장 큰 곳은 GR-1 휴머노이드 (+17.3%p)

데모 수 30 / 100 / 300 전 구간에서 동일한 경향

Post-training 결과 — 시뮬레이션

Post-Training Evaluations

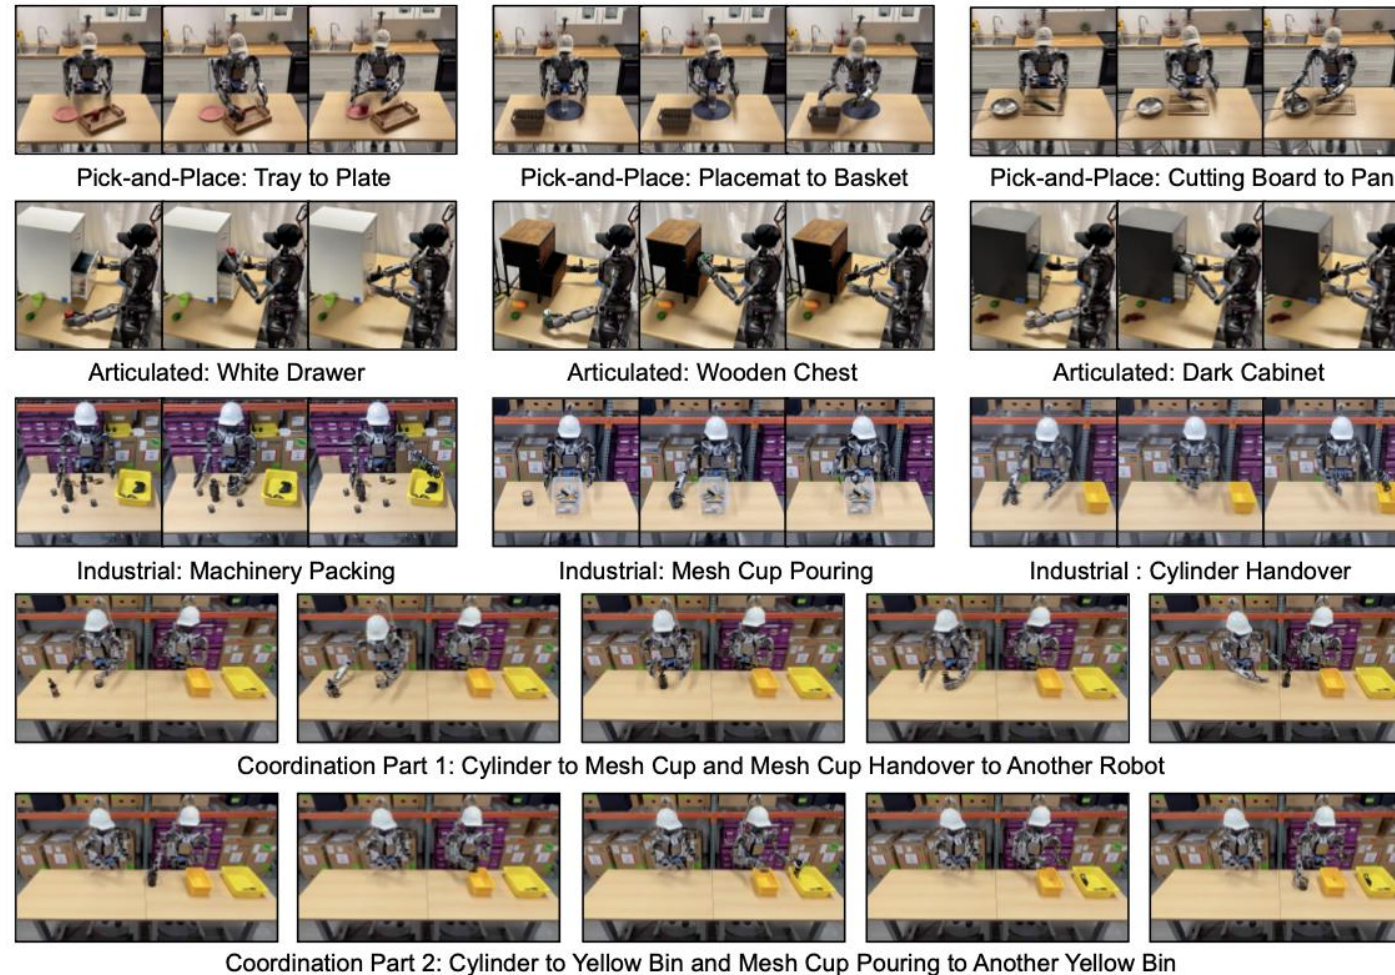



Figure 8: **Real-World Tasks.** All images are captured from policy rollouts of GR00T-N1-2B and models post-trained from GR00T-N1-2B. **(Top) Pre-training evaluations.** We design two manipulation tasks to assess our pretrained models. The left image shows a left-to-right handover, while the right image illustrates the placement of novel objects into an unseen target container. **(Bottom) Post-training evaluations.** We introduce four distinct task categories. From top to bottom, we present examples of object-to-container pick-and-place, articulated object manipulation, industrial object manipulation, and multi-agent coordination.

Post-training 결과 — 실로봇




데이터 효율성:

GR00T-N1-2B는 10% 데이터만으로(42.6%) Diffusion Policy의 전체 데이터(46.4%) 성능에 근접




Post-training 결과 — LAPA/IDM 비교



시뮬레이션(RoboCasa)에서는 작업당 30, 100, 300개의 실제 데모 데이터를 사용하며, 각 작업에 3,000개의 신경 궤적을 추가로 투입하여 성능을 보강함

Post-training 결과 — LAPA/IDM 비교



실제 로봇 환경에서는 데이터가 매우 제한적인 상황(전체 데이터의 10%)을 가정하고, 작업당 100개의 신경 궤적을 활용하여 학습 효율을 테스트함



정성 평가

Post-trained 모델 vs Diffusion Policy

GR00T N1의 모션이 전반적으로 훨씬 부드럽고 (smoother) Grasping 정확도가 눈에 띄게 높음

반면 Diffusion Policy는 초기 프레임에서 움직임이 굳어있거나(immobility), grasping이 부정확한 경우가 잦아 실로봇 벤치마크에서 낮은 성공률로 이어짐

Pre-trained 체크포인트 사례

Pre-trained 모델: 사과가 왼손 쪽에 있어도 왼손 → 오른손 handover로 해결 (본 적 없는 상황인데도)

Post-trained 모델: 이 능력을 잃음 (post-training 데이터가 전부 오른손만 사용했기 때문) — 파인튜닝이 사전학습의 일부 일반화 능력을 좁힐 수 있다는 트레이드오프를 보여줌

향후 연구 방향

1. 긴 시간 지평을 가진 loco-manipulation(이동 및 조작 결합) 과제

현재 GR00T N1은 주로 short-horizon (단기 호흡)의 탁상 위 조작 작업(tabletop manipulation tasks)에 초점이 맞춰져 있음.

2. 합성 데이터 생성 기법의 품질과 물리적 타당성 문제

비디오 생성 모델과 자동화된 궤적 합성 시스템이 여전히 물리 법칙을 엄격히 준수하면서 다양하고 반사실적인(counterfactual) 데이터를 생성하는 데에는 한계가 있어 합성 데이터의 품질과 변동성이 제한적임.

3. 비전-언어 백본(Vision-Language Backbone)의 성능 고도화 필요

저자들은 더 강력한 비전-언어 모델을 도입함으로써 로봇의 공간 추론 능력, 언어 이해력, 그리고 환경에 대한 적응력을 한층 더 향상시킬 수 있을 것으로 기대하고 있음

스터디 전체 정리 — 마지막 발표자의 특권

	액션 표현	생성 방식	백본	데이터
RT-1 (2022)	이산 토큰	자기회귀	EfficientNet + Transformer	텔레옴 (단일 로봇)
RT-2 (2023)	이산 토큰(텍스트)	자기회귀	PaLI-X / PaLM-E	웹 VQA + 로봇 코파인튜닝
ACT (2023)	액션 청크 (연속)	CVAE 디코더	ResNet + Transformer	ALOHA 소량 텔레옴
Diffusion Policy (2023)	액션 시퀀스 (연속)	확산 디노이징	U-Net / Transformer	태스크별 소량 데모
OpenVLA (2024)	이산 토큰	자기회귀	Prismatic (Llama-2 7B)	OXE 크로스 임베디먼트
$\pi 0$ (2024)	액션 청크 (연속)	Flow matching	PaliGemma + 액션 전문가(MoE)	자체 + OXE
GR00T N1 (2025)	액션 청크 H=16	Flow matching (K=4)	Eagle-2 + DiT (cross-attn)	실로봇·시뮬·생성 영상·사람 영상

가로로 보면 아키텍처의 수렴이, 오른쪽 끝 열을 세로로 보면 데이터의 확장이 보입니다.

앞선 발표 내용은 각 발표자 슬라이드와 한 번 대조해 확인하세요.